

TRABAJO ECONOMETRÍA RENTABILIDAD-VOLATILIDAD

Hecho por: Iker García, Adrián Quintero, Jaime Antón, Miguel Martín-Caro y Miguel Marcano.



1. INTRODUCCIÓN.....	
1.1 PERFIL DE LA EMPRESA Y CONTEXTO MACROECONÓMICO.....	
1.2 DEFINICIÓN DE LAS VARIABLES.....	
1.3 OBJETIVOS DEL ESTUDIO.....	
2. BLOQUE 2: PREPARACIÓN DE DATOS.....	
2.1 GRÁFICOS DE SERIES TEMPORALES.....	
2.2 HISTOGRAMAS Y TEST DE NORMALIDAD.....	
2.3 FAC Y FACP.....	
3. BLOQUE 3: ECONOMETRÍA RENTABILIDAD.....	
3.1 TEST ADF.....	
3.2 IDENTIFICAR ORDEN (p,q).....	
3.3 ESTIMACIÓN DE LOS MODELOS AR(1) Y MA (1).....	
3.4 DIAGNÓSTICO DE RESIDUOS DE AR(1).....	
3.5 PREDICCIÓN Y VALIDACIÓN FUERA DE MUESTRA.....	
4. BLOQUE 4: ECONOMETRÍA VOLATILIDAD.....	
4.1 IDENTIFICACIÓN ORDEN (P,Q).....	
4.2 ESTIMACIÓN DE ARIMA (2,1,5) Y ARIMA (1,1,5).....	
4.3 DIAGNÓSTICO DE RESIDUOS ARIMA (1,1,5).....	
4.4 PREDICCIÓN Y VALIDACIÓN FUERA DE MUESTRA.....	
5. BLOQUE 5: ANÁLISIS INTEGRADO.....	
5.1 TEST DE CAUSALIDAD DE GRANGER.....	
5.2 ANÁLISIS DE EPISODIOS DE ESTRÉS E IMPACTO SECTORIAL.....	
5.3 RELACIÓN RENTABILIDAD-VOLATILIDAD.....	
6. CONCLUSIONES Y LIMITACIONES.....	
7. BIBLIOGRAFÍA.....	
8. ANEXOS.....	

MUY IMPORTANTE REVISAR ANEXO (CONSTRUCCIÓN MODELO VAR COMO AMPLIACIÓN DEL TRABAJO)

1. INTRODUCCIÓN

1.1 PERFIL DE LA EMPRESA Y CONTEXTO MACROECONÓMICO

Este trabajo se centra en el análisis de la empresa Palantir Technologies, la cual es una empresa pública cotizada en la bolsa americana de NASDAQ dedicada al desarrollo de inteligencia artificial y análisis de big data. Palantir es uno de los gigantes de inteligencia artificial, estando a la vanguardia de todas las novedades. Es un representante muy grande del sector con mayor potencial de crecimiento actualmente, pero a la vez tiene un comportamiento financiero muy complejo y cambiante.

Para entender cómo se comporta Palantir primero vamos a explicar la dinámica de la empresa en el periodo 2022-2024. Durante el 2022 la economía global y más concretamente la estadounidense sufrió una notable bajada debido al endurecimiento de las políticas monetarias por parte de la Reserva Federal de los Estados Unidos para reducir el efecto de la inflación. Esta política afectó sobre todo a las empresas con tendencia de crecimiento como lo son las dedicadas a la inteligencia artificial, provocando caídas en sus precios de acciones y subidas en su inestabilidad. Con el crecimiento y democratización de la IA, este perfil de empresas y entre ellas Palantir recuperó estabilidad, viendo un crecimiento de su rentabilidad y eso lo podremos apreciar más tarde durante el trabajo.

Todo esto convierte a Palantir en un ejemplo perfecto de explicación del contexto macroeconómico mundial de los últimos años, pero también de la dificultad de aplicar modelos estadísticos a entornos tan cambiantes como son los mercados de valores, ya que va mucho más allá de lo teórico y entran miles de variables más de las que podemos plantear en una primera pasada.

1.2 DEFINICIÓN DE LAS VARIABLES

Para hacer este trabajo hemos utilizado una muestra de 750 observaciones que representa la reacción de rentabilidad y volatilidad de la empresa Palantir ante todos los cambios de los que acabamos de hablar. La división se ha planteado cómo 690 observaciones para estimar los modelos, o lo que vamos a llamar dentro de muestra, y 60 observaciones que vamos a utilizar para validar las predicciones, que lo vamos a llamar fuera de muestra. El estudio gira en torno a dos variables:

→ Rentabilidad: Es de tipo logarítmico $\ln(P_t / P_{t-1})$, siendo P el precio de las acciones de Palantir en el día t. Se utiliza en formato logarítmico ya que facilita la estacionariedad para series financieras.

→ Volatilidad: Incluida a un plazo de 5 días, que se trata de una desviación estándar de la rentabilidad. Lo que hace es explicarnos la variación del riesgo a corto plazo y nos ayuda a encontrar los periodos de estrés de los que hablaremos a lo largo del trabajo.

1.3 OBJETIVOS DEL ESTUDIO

Para completar este trabajo vamos a utilizar de referencia 5 objetivos explicados a continuación, y para ir cumpliéndolos vamos a aplicar análisis de series mediante la metodología Box-Jenkins.

→ Modelizar rentabilidad logarítmica mediante metodología univariante: Vamos a tratar de identificar si la serie tiene estructura de autocorrelación y memoria de datos anteriores que nos permita predecir la rentabilidad futura de Palantir. (Bloque 3)

→ Modelizar volatilidad mediante modelos ARMA/ARIMA: En este objetivo intentaremos ajustar un modelo que evalúe si los periodos de alta volatilidad (los periodos de 2022 de los que acabamos de hablar) predicen los valores de la volatilidad futura. (Bloque 4).

→ Realizar predicciones y validación fuera de muestra: En este objetivo vamos a ver si los modelos tienen alto o bajo poder predictivo sobre datos no vistos (las 60 observaciones fuera de muestra). Para esto emplearemos las métricas de MAE y RMSE que miden el error de predicción. (Bloques 3 y 4)

→ Analizar relación Lead-Lag entre rentabilidad y volatilidad: Con la función de correlación cruzada y el test de causalidad de Granger, veremos si hay una relación entre ambas variables que permita a una predecir el valor siguiente de la otra. En base a este resultado indicaremos si conviene más utilizar modelos univariantes o multivariantes (VAR). (Bloque 5).

→ Evaluar riesgo-retorno y utilidad para inversores: En este objetivo vamos a mezclar ambas variables además de añadir métricas financieras como el ratio de Sharpe o métodos gráficos como un gráfico de dispersión para ver si Palantir es atractivo para los inversores. (Bloque 5).

2. BLOQUE 2: PREPARACIÓN DE DATOS

Podemos ver que dentro de los datos que vamos a emplear tenemos 752 filas, 3 columnas, el rango de fechas es desde enero de 2022 hasta diciembre de 2024. Tenemos 5 valores NA para volatilidad y 1 para rentabilidad. Para la rentabilidad tenemos 751 observaciones y para volatilidad 747. La distribución de datos será para la rentabilidad de 690 para observación y 60 para validación y para volatilidad 687 para observación y 60 para validación.

	Variable	N	Media	Mediana	Desv_Std	Minimo	Maximo	Asimetria	Curtosis
1	Rentabilidad	690	0.0001	0.0003	0.0246	-0.1514	0.1269	-0.1466	7.4106
2	Volatilidad	687	0.0213	0.0187	0.0122	0.0032	0.0766	1.8046	7.5086

Figura 1: Métricas Introductorias para las variables rentabilidad y volatilidad.

Para la rentabilidad podemos apreciar que la media es muy cercana a 0, la desviación estándar nos indica que Palantir se mueve un $\pm 2,5\%$ y su rango es bastante amplio, ya que va desde -15% hasta 12% , indicándonos lo volátil que es Palantir. La asimetría negativa de $-0,14$ nos da a entender que Palantir tiene más caídas fuertes que subidas. Por último la curtosis es de $7,4$, que supera por mucho el valor normal de 3 , lo que nos indica que tiene colas pesadas, es decir, que tiene bastantes más cambios extremos de los que se esperarían en una distribución normal.

Para la volatilidad podemos decir que ronda el $2,13\%$, por la asimetría positiva vemos que es más probable que la volatilidad suba bruscamente, que cuadra con el perfil de empresa de Palantir y también con lo que nos dice la rentabilidad. La curtosis tiene un valor parecido a la rentabilidad, también lejos de la normalidad, lo que quiere decir que las subidas de rentabilidad son bastante extremas y no graduales. Ninguna de las variables parece seguir una distribución normal.

2.1 GRÁFICOS DE SERIES TEMPORALES



Figura 2: Series temporales para las variables Rentabilidad y Volatilidad.

Ahora vamos a interpretar los gráficos de series temporales. Vamos a distinguir entre el de arriba que corresponde a la rentabilidad y el de abajo que corresponde a la volatilidad. El de la rentabilidad ronda constantemente 0, como ya explicamos en el anterior apartado con la media. Los periodos de alta volatilidad se encuentran muy juntos (2022 y 2023), es decir, que los puntos muy volátiles suelen estar acompañados de otros periodos también muy volátiles. No se puede apreciar ninguna tendencia de crecimiento o decrecimiento, por lo que la serie parece estacionaria.

Para la volatilidad, podemos ver que la serie siempre es positiva, lo cual cuadra con que sea una desviación estándar. Los picos más fuertes se dan a principios de 2022, coincidiendo con las caídas más grandes de la rentabilidad de Palantir. Podemos ver que hay una tendencia decreciente suave que podría hacer que la serie no sea estacionaria en media, y por tanto haya que diferenciar, aunque más tarde haremos comprobaciones con los tests. Por último, podemos ver que cuando hay un pico de volatilidad, tarda en volver a los niveles anteriores, por lo que puede indicar autocorrelación alta, pero ahora lo veremos con FAC y FACP.

2.2 HISTOGRAMAS Y TEST DE NORMALIDAD




Figura 3: Histogramas para variables rentabilidad y volatilidad

Ahora vamos a analizar los histogramas. El de la rentabilidad (izquierda) parece tener una forma a priori de normal, pero tiene colas más largas y además observaciones sueltas en los extremos que no aparecerían en una normal y que corresponden a casos extremos, lo que es típico en variables financieras. Para el de la volatilidad, podemos ver que está muy desequilibrado. La gran parte de los días la volatilidad es baja, pero podemos apreciar en una de las colas que se llega a valores muy

altos. Además la media esta descentrada hacia la izquierda reforzando lo que hemos comentado antes de la asimetría positiva.

Ahora vamos con el test de Jarque-Bera para comprobar todo lo que hemos dicho antes sobre la normalidad. Después de pasar este test veremos si las series siguen una distribución normal o no, refutando lo que hemos dicho en los histogramas. La H_0 es que la serie sigue una distribución normal, mientras que H_1 nos dice que no sigue una distribución normal.

Variable	Comparación P-valor	Conclusión
Rentabilidad	2.2e-16	Rechazamos H_0 , por lo que la serie no sigue una distribución normal.
Volatilidad	2.2e-16	Rechazamos H_0 , por lo que la serie no sigue una distribución normal.

Al final ninguna de las dos series sigue una distribución normal, como ya barajamos al ver los histogramas. Al no trabajar con series que sigan una distribución normal, tenemos que modelizar series con ARMA o ARIMA (dependiendo de si tenemos que diferenciar, que veremos más tarde).

2.3 FAC Y FACP




Figura 4: FAC Y FACP para variables rentabilidad y volatilidad

Ahora vamos a estudiar significatividad, correlación y estacionalidad con la FAC y FACP como ya adelantamos anteriormente. Las dos gráficas de arriba son las de rentabilidad y las dos de abajo las de volatilidad. Para la rentabilidad tanto la FAC como la FACP presentan patrones muy parecidos, casi todos los retardos, excepto el 1 (lo que pasa siempre) y el 14 están dentro de las bandas, indicándonos que no son significativos, pero además que la rentabilidad tiene poca autocorrelación, es decir, que es muy complicado predecir la rentabilidad de hoy de una acción con las rentabilidades pasadas. El patrón de la rentabilidad parece aproximarse mucho a ruido blanco, es decir, casi la completa aleatoriedad.

Para la volatilidad, el patrón cambia mucho. Los retardos van cayendo muy lentamente, pero aún así todos tienen valores muy altos, es decir, que tiene una alta autocorrelación, y por tanto, la volatilidad de hoy está muy relacionada y depende en gran parte de los valores anteriores de volatilidad. En la FACP el patrón cambia, pero los retardos 1, 2 y 5 son significativos. La caída de retardos muy lenta en lugar de exponencial nos puede indicar la existencia de tendencia, por tanto, no estacionalidad y ahí tendríamos que diferenciar, pero después haremos los tests.

3. BLOQUE 3: ECONOMETRÍA RENTABILIDAD

3.1 TEST ADF

Ahora planteamos el test de Dickey-Fuller Aumentado, que plantea una H_0 de que la serie tiene una raíz unitaria y por tanto no es estacionaria, mientras que H_1 es que la serie no tiene raíz unitaria y es estacionaria.

Dickey-Fuller y KPSS RENTABILIDAD	P-valor
-9,46	0,01
0,26	0,1

Como el P-valor es <0.05 tenemos que rechazar H_0 y por tanto decimos que la serie de la rentabilidad no tiene raíz unitaria y es estacionaria, para el ADF, mientras que para el KPSS aceptamos la H_0 por lo que también coincide en que es estacionaria. Como es estacionaria no tenemos que diferenciar (que es lo mismo que decir $d=0$), así que para la rentabilidad ya sabemos que no vamos a usar modelo ARIMA. Esto tiene sentido en relación con lo que hemos dicho antes en los gráficos.

3.2 IDENTIFICAR ORDEN (p,q)

Como ya dijimos durante el análisis anterior de la FAC y FACP, la rentabilidad, no tiene estructura temporal ni autocorrelación, ya que casi todos los retardos no superan las bandas. Los que pasan las bandas pueden ser retardos aislados o atípicos, que realmente no nos indica nada. Ahora para contrastar, vamos a implementar también AIC y BIC.

```

--- TOP 5 MODELOS POR AIC ---
> print(head(resultados, 5))
  p q      AIC      BIC
1  0 1 -3150.903 -3137.293
4  1 0 -3150.903 -3137.293
14 3 2 -3150.323 -3118.566
8  2 0 -3148.906 -3130.759
2  0 2 -3148.906 -3130.759
>

--- TOP 5 MODELOS POR BIC ---
> print(head(resultados_bic, 5))
  p q      AIC      BIC
1  0 1 -3150.903 -3137.293
4  1 0 -3150.903 -3137.293
8  2 0 -3148.906 -3130.759
2  0 2 -3148.906 -3130.759
5  1 1 -3148.903 -3130.756
~ |
>

```

Figura 5: Clasificación de los 5 mejores modelos por los criterios de información AIC y BIC para rentabilidad.

Los dos mejores modelos por el criterio de AIC, AR(1) o ARMA (1,0) y MA(1) o ARMA (0,1) empatan con un AIC= -3150.9 Y un BIC = -3137,29. Como la rentabilidad tiene tan poca rentabilidad, es normal que el modelo óptimo sea de tan poco orden, porque con un parámetro se recoge bien la información y añadir más no aporta nada. Por el criterio del BIC el resultado es el mismo, empatando ambos modelos AR(1) y MA(1). El ARMA (3,2) tiene un buen valor de AIC pero en el BIC no se sostiene. De momento vamos a contar con los dos modelos y estimar sus residuos, y luego decidiremos con cuál nos quedamos.

3.3 ESTIMACIÓN DE LOS MODELOS AR(1) Y MA (1)

	Coef	SE	T-Ratio	Signif
AR (1)	0.0011	0.0381	0.0285	NO
intercept	0.0001	0.0009	0.1274	NO

	Coef	SE	T-Ratio	Signif
MA (1)	0.0011	0.0382	0.0286	NO
intercept	0.0001	0.0009	0.1275	NO

Ninguno de los coeficientes es significativo en ninguno de los dos modelos, ni siquiera los interceptos son significativos. Podemos decir con casi total seguridad que la rentabilidad de Palantir es ruido blanco, ya que la rentabilidad de hoy no depende prácticamente nada de la rentabilidad de ayer, que tiene sentido y se puede unir con lo que decíamos en las FAC y FACP. Vamos a implementar y a tener en cuenta también un ARMA (1,1) y lo vamos a comparar.

Estimación ARMA (1,1)	Coef
AR(1)	0,0373
MA(1)	-0,0362
Intercept	0,0001

Para el ARMA (1,1) vemos que el coeficiente de AR(1) es 0,0373 y el de MA(1) es prácticamente el mismo coeficiente pero en negativo, por lo que lo que aporta uno lo quita el otro y pierde el sentido casi totalmente. El ARMA tiene problemas de estimación por este motivo, entonces un solo parámetro es suficiente (AR o MA) y meter dos parámetros, es decir, un ARMA (1,1) es sobreparametrizar, o meter más parámetros de los que son necesarios.

Ahora que ya sabemos que el modelo ARMA (1,1) queda descartado, vamos a decidir entre AR(1) y MA (1). Sabemos que tienen los mismos valores de AIC y BIC, entonces vamos a plantear el test de Ljung-Box sobre los residuos, para ver cuál de los dos decidimos.

Test Ljung-Box	MAE	RMSE	P-VALOR
AR(1)	0,014	0,018	0,852
MA(1)	0,014	0,018	0,852

Después de tirar el test Ljung-Box vemos que los dos modelos tienen las mismas métricas y tampoco podremos decidir en base a estos resultados.

Ninguno de los dos modelos tiene coeficientes significativos y tiene las mismas métricas para todos los test formales de decisión, pero nos vamos a quedar con el AR(1) ya que la interpretación es más sencilla para el AR (la rentabilidad de hoy depende de la rentabilidad anterior) que el MA (la rentabilidad de hoy depende de los errores de ayer).

3.4 DIAGNÓSTICO DE RESIDUOS DE AR(1)




Figura 6: Gráfico resumen de residuos, FAC, Q-Q Plot e Histograma para AR(1), que ajusta rentabilidad.

En este paso vamos a aplicar métodos formales (test Ljung-Box y Jarque Bera) y no formales (gráficos) sobre los residuos del modelo que hemos elegido. AR(1). Igual que dijimos al principio del bloque, los residuos están en torno al 0, y podemos ver los mismos ciclos de volatilidad al principio de la serie. Para la PAC vemos todas los retardos dentro de las barras, y que los residuos no tienen autocorrelación como dijimos antes (la rentabilidad de hoy no depende de las cifras anteriores). En el Q-Q plot queremos demostrar el peso de las colas de las que ya hablamos, indicando la presencia de valores extremos, diferenciándose de la distribución normal, como también vemos en el histograma.

Métodos formales	Ljung-Box (10 retardos)	Ljung-Box (20 retardos)	Jarque-Bera
AR (1)	0,8529	0,4491	2.2e-16

Con los métodos formales podemos decir que para 10 retardos, el modelo nos obliga a aceptar H_0 por lo que los residuos son ruido blanco o lo que es lo mismo, no hay autocorrelación entre los retardos. Si ampliamos hasta 20 retardos nos sale el mismo resultado, por lo que podemos decir con seguridad que el modelo es válido. Para el test de Jarque-Bera, el p -valor $< 0,05$ por lo que rechazamos H_0 , entonces los residuos no siguen una distribución normal como ya podíamos adelantar viendo el histograma.

3.5 PREDICCIÓN Y VALIDACIÓN FUERA DE MUESTRA




Figura 7: Gráfico de predicción fuera de muestra para la variable rentabilidad.

El modelo no parece muy bueno para la predicción de la rentabilidad, ya que los valores predichos están constantemente muy cercanos a 0, por lo que no adivina si la rentabilidad de Palantir va a subir y bajar sino que será aproximadamente 0. Por otra parte si que nos indica un rango preciso en el que estará la rentabilidad. Con un 95% de nivel de confianza la rentabilidad va a estar aproximadamente entre -0.048 y 0.048 y casi todos los valores están dentro del intervalo de confianza, por lo que es bastante preciso en eso.

MAE	RMSE
0.0148	0.0190

El MAE nos explica que el modelo se equivoca en 1,48% cada día y siendo el movimiento un 2,5% parece más grande de lo que debería ser. El RMSE tiene una cifra parecida al MAE pero más grande ya que penaliza más los errores más grandes. Lo que podemos sacar de estas métricas y del gráfico es que el modelo es válido como ya hemos visto, pero no tiene una gran capacidad predictiva para la rentabilidad. Esto también es normal ya que responde a la teoría de eficiencia de mercado.

Con esta parte cubrimos parte del objetivo de predicción y validación de MAE y RMSE y el objetivo de modelizar la rentabilidad con ARMA (en este caso no nos ha hecho falta aplicar ARIMA).

4. BLOQUE 4: ECONOMETRÍA VOLATILIDAD

Para comenzar vamos a seguir los pasos que hemos seguido con la rentabilidad. Primero vamos a estudiar si es estacionaria o no. Aplicaremos igual que antes los dos test para contrastar.

Dickey-Fuller y KPSS Volatilidad	P-valor
-7,72	0,01
3,26	0,01

Para la volatilidad tenemos que en el ADF tenemos que rechazar la H_0 , por lo que la serie no tiene raíz unitaria y entonces es estacionaria. Para el KPSS rechazamos también la H_0 , pero en este caso la conclusión a la que llegamos es diferente, y es que la serie no es estacionaria. Aquí encontramos una contradicción que se puede explicar porque es una serie que cuando hay una subida o bajada muy fuerte, tarda mucho en recuperar los valores estables, y es por eso que la no estacionariedad la detecta el KPSS y no el ADF, porque no termina de haber una raíz unitaria.

Como los tests se contradicen vamos a probar una opción sin diferenciar (ARMA) y otra diferenciando (ARIMA), y veremos cuál funciona mejor para quedarnos con ese.

4.1 IDENTIFICACIÓN ORDEN (P,Q)

En este apartado vamos a identificar el orden para ambas opciones que hemos dicho antes, tanto diferenciando como sin diferenciar.




Figura 8: Gráficos de FAC y FACP para la variable volatilidad.

Estos gráficos son la FAC y FACP con el modelo ya diferenciado. Una vez hemos diferenciado del modelo, es decir, aplicado la variable d para restar a cada valor el valor anterior para hacer la serie estacionaria, mediante eliminar el efecto que hace que KPSS identifique la serie como no estacionaria (lo que hemos explicado de las subidas y bajadas fuertes y cómo se recupera).

Cuando la diferenciamos ya no vemos una caída gradual en la FAC, sino inmediata por lo que la diferenciación ya ha eliminado el efecto del que hablamos que la hacía no estacionaria.

	Modelo	AIC	BIC
18	ARIMA(2,1,5)	-5055.42	-5019.18
12	ARIMA(1,1,5)	-5054.37	-5022.65
24	ARIMA(3,1,5)	-5053.96	-5013.18
30	ARIMA(4,1,5)	-5052.42	-5007.11
36	ARIMA(5,1,5)	-5050.97	-5001.13

Figura 9: Clasificación de top 5 modelos por AIC y BIC para la variable volatilidad.

Si vemos los mejores modelos que nos salen, prácticamente todos son ARIMA con una diferenciación, es decir, $d=1$, lo que cuadra con lo que hemos dicho viendo la FAC, que con aplicar la primera diferenciación ya se ven los rasgos de una serie estacionaria. Con esto ya nos quitamos la duda de cuál era mejor, el modelo sin diferenciar, o el modelo diferenciado (claramente el diferenciado). Por los criterios de AIC y BIC el mejor modelo es ARIMA (2,1,5) y también vamos a evaluar la segunda opción que tiene unos resultados muy parecidos, el ARIMA (1,1,5).

4.2 ESTIMACIÓN DE ARIMA (2,1,5) Y ARIMA (1,1,5)

	Coef	SE	t_ratio	Signif		Coef	SE	t_ratio	Signif
ar1	0.3959	0.1159	3.4143	SI	ar1	0.2517	0.0730	3.4500	SI
ar2	-0.1657	0.0944	-1.7564	NO	ma1	-0.2769	0.0662	-4.1805	SI
ma1	-0.4147	0.1098	-3.7779	SI	ma2	-0.1040	0.0382	-2.7272	SI
ma2	0.0435	0.0923	0.4714	NO	ma3	-0.0725	0.0398	-1.8237	NO
ma3	-0.0743	0.0418	-1.7763	NO	ma4	-0.1090	0.0384	-2.8344	SI
ma4	-0.1129	0.0391	-2.8854	SI	ma5	-0.3939	0.0394	-9.9900	SI
ma5	-0.3961	0.0401	-9.8725	SI					

	AIC	BIC
ARIMA (2,1,5)	-5005.42	-5019,18
ARIMA (1,1,5)	-5054,37	-5022,65

Tanto para el ARIMA (2,1,2) como para el ARIMA (2,1,1) todos los coeficientes son significativos, por los que los dos en este criterio empatan y son muy válidos. Además que todos los coeficientes sean significativos, nos da a entender, que a diferencia de la rentabilidad, la estructura de la volatilidad es mucho más predecible. Por AIC y BIC gana ARIMA (2,1,2) por lo que es con el que nos vamos a quedar.

Para el ARIMA (2,1,5) tiene más coeficientes significativos, cuatro significativos y tres no significativos. Que el coeficiente AR(2) no sea significativo nos puede dar señales de que alomejor el orden 2 autorregresivo no es necesario. Para el ARIMA (1,1,5) tiene cinco significativos, siendo un

resultado mucho más limpio de lo que presenta el ARIMA (2,1,5) a pesar de que tenga mejores resultados de AIC y BIC. Por el criterio de información quedan muy igualados, y por el de significatividad de coeficientes parece que el ARIMA (1,1,5) tiene mucho mas sentido, por lo que es con el que nos vamos a quedar.




Figura 10: Representación círculo unidad para la variable volatilidad.

Además de estudiar la significatividad de los coeficientes y las medidas de AIC y BIC, queremos asegurarnos de la validez del modelo comprobando estacionariedad e invertibilidad una vez se ha aplicado la diferenciación. Sabemos que un proceso es estacionario e invertible si las raíces inversas de los polinomios se encuentran dentro del círculo unitario (o si las raíces de los polinomios de retardos están fuera).

En el gráfico podemos apreciar que el punto dentro del círculo izquierdo que es el de la parte autorregresiva se encuentra dentro del círculo unitario, por lo que nos demuestra estacionariedad. El círculo derecho demuestra invertibilidad, y teniendo los cinco puntos en su interior, nos indica que el modelo también es invertible, por lo que el modelo es muy válido. Por último más adelante lo comprobaremos con el test de Ljung-Box.

Recordemos que el número de puntos en cada círculo depende del orden de cada modelo, es decir, el círculo AR tiene un punto porque su orden es 1, y el de MA 5 porque su orden es 5

4.3 DIAGNÓSTICO DE RESIDUOS ARIMA (1,1,5)




Figura 11: Resumen de residuos, FAC, Q-Q Plot e histograma para variable volatilidad.

En el gráfico de residuos prácticamente todos los valores son muy cercanos a 0, aunque hay picos más exagerados al principio de la serie, lo que indica que cuando hay alta volatilidad, el modelo tiende a equivocarse más, pero cuando la volatilidad se estabiliza el modelo funciona mejor. Para la FAC todos los residuos están dentro de las bandas, excepto el retardo 1, que es el que siempre va a superar las bandas, indicándonos a priori que los residuos no tienen autocorrelación, aunque comprobaremos con el test formal. Para el gráfico Q-Q podemos ver que los puntos se desvían en la parte izquierda, lo que nos indica que el modelo no captura bien los valores muy altos de volatilidad. Como ya comentamos, el histograma nos indica que los residuos no son normales, aunque ahora lo confirmaremos con Jarque-Bera.

Ljung-Box y Jarque-Bera	P-valor	Decisión
Ljung-box (10 retardos)	0,9311	Aceptamos H_0 por lo que los residuos no tienen autocorrelación (son ruido blanco).
Ljung-box (20 retardos)	0,654	Aceptamos H_0 por lo que los residuos no tienen autocorrelación.
Jarque-Bera	2.2e-16	Rechazamos H_0 , por lo que la serie no sigue una distribución normal.

El test de Ljung-Box tanto viendo 10, como 20 retardos, nos indica que los residuos se comportan como ruido blanco y no tienen autocorrelación. Por otra parte el test de Jarque-Bera nos indica que la serie no sigue una distribución normal como ya podíamos adelantar viendo el Q-Q y el histograma.

4.4 PREDICCIÓN Y VALIDACIÓN FUERA DE MUESTRA

Ahora vamos a hacer la predicción de la volatilidad y la validación con el conjunto de 60 datos que asignamos en un inicio.



Figura 12: Gráfico predicción fuera de muestra para variable volatilidad.

Aquí ya podemos apreciar una diferencia con la rentabilidad, donde la predicción constante era muy cercana a 0, aquí podemos ver que también empieza muy cercana a 0, pero después sube y se estabiliza en 0,015 aproximadamente. No captura exactamente toda la volatilidad, pero si que se aproxima más de lo que lo hacía la rentabilidad. El intervalo de confianza del 95% captura todos los datos, haciendo más de lo que hacía la rentabilidad también (si recordamos había algunos datos por fuera del intervalo de confianza).

MAE	RMSE
0,0064	0,0082

Viendo el MAE podemos ver que el modelo se equivoca un 0,64% al predecir la volatilidad, que teniendo en cuenta que la media de la volatilidad es de 1,74% es un error que ocupa una parte importante. Con el RMSE pasa algo parecido a lo que nos encontramos en la rentabilidad, que el RMSE es más grande, ya que habrá errores más grandes y el RMSE penaliza más este tipo de errores.

Podemos decir que la volatilidad se puede predecir mejor que la rentabilidad, ya que el modelo de la volatilidad es capaz de capturar de forma general el modelo, mientras que el modelo planteado para la rentabilidad solo era capaz de predecir la media.

5. BLOQUE 5: ANÁLISIS INTEGRADO

Ahora vamos a plantear la relación entre volatilidad y rentabilidad, es decir, las dos variables con las que hemos trabajado a lo largo de este trabajo.




Figura 13: Gráfico Correlación Cruzada (CCF), rentabilidad-volatilidad

Para relacionar ambas variables vamos a interpretar este gráfico de correlación cruzada. Para introducir, los retardos negativos lo que nos indica es que la volatilidad adelanta a la rentabilidad y los retardos positivos al revés, que la rentabilidad adelanta a la volatilidad. Como podemos ver en el gráfico, no hay prácticamente retardos positivos, y de estos, no hay ninguno significativo, todos los significativos son negativos. Esto lo que nos dice es que la rentabilidad de hoy no predice la volatilidad de mañana, y puede ser porque la relación entre ambas variables no sea lineal.

Lo que nos dicen los retardos negativos, es que la volatilidad adelanta a la rentabilidad, con una relación inversa, es decir, que cuando sube la rentabilidad, crea un impacto en el que la rentabilidad pasa a bajar o a ser negativa.

5.1 TEST DE CAUSALIDAD DE GRANGER

Ahora vamos a aplicar el test de Granger, recordemos que tiene como H_0 que una variable no causa a la otra. Vamos a hacer dos tests de Granger, el primero para ver si la rentabilidad causa a la volatilidad, y el segundo para ver si la volatilidad causa a la rentabilidad.

Rentabilidad-Volatilidad	Retardo 1	Retardo 5	Retardo 10
P-valores	0,70	0,51	0,06

Para los tres valores de retardos, no rechazamos la H_0 , por lo que la rentabilidad no causa a la volatilidad.

Volatilidad-Rentabilidad	Retardo 1	Retardo 5	Retardo 10
P-valores	0,57	0,54	0,58

Para los otros tres valores de retardos que estudian la relación entre volatilidad y rentabilidad, también aceptamos H_0 , por lo que la volatilidad de ayer no predice la rentabilidad de hoy. Con Granger no afirmamos que no exista ninguna relación entre rentabilidad y volatilidad, sino que ninguna de las dos variables es capaz de aportar información significativa a la otra para mejorar los resultados de su predicción.

Esto parece contradictorio con lo que hemos comentado en la correlación cruzada, pero los valores de correlaciones que salían en el gráfico eran bajos, haciendo las correlaciones débiles. El test de Granger es más exigente y no solo estudia la correlación, sino que una variable aporte información a la otra (como acabamos de comentar), cosa que ninguna de las variables hace a la otra por los valores de p-valor que nos han salido.

Por tanto, ya que ni podemos predecir la rentabilidad usando la volatilidad pasada, ni la volatilidad usando la rentabilidad pasada, no tiene sentido crear un modelo VAR, sino crear modelos separados e individuales.

5.2 ANÁLISIS DE EPISODIOS DE ESTRÉS E IMPACTO SECTORIAL

Date	rentabilidad	volatilidad
<dtm>	<dbl>	<dbl>
1 2022-05-04 00:00:00	0.0134	0.0766
2 2022-04-29 00:00:00	-0.151	0.0757
3 2022-02-04 00:00:00	0.127	0.0753

Umbral de estrés	Días en estrés	Porcentaje
0.0396	55	8%

Para comprender la relación entre rentabilidad y volatilidad vamos a situarnos en el contexto de Palantir y del sector en general de la inteligencia artificial. En el periodo de 2022-2024 se llegaron hasta 55 episodios de estrés sobre la muestra de 687 observaciones. Esto representa el 8% del total de las observaciones. La mayor cantidad de ellos se encuentran en 2022 relacionado con el endurecimiento del ciclo financiero de la reserva federal estadounidense, subiendo los tipos, con su mayor cifra en abril de 2022 llegando a 7,66% de volatilidad.

El umbral de estrés que hemos establecido es cuando supera el 3,96% de volatilidad.

Este contexto de la subida de tipos y endurecimiento de la economía tuvo impacto tanto en la rentabilidad como en la volatilidad. En la rentabilidad prácticamente todas las empresas del sector IA quedaron penalizadas, y lo podemos apreciar en la cifra de curtosis que introdujimos al principio del trabajo (7,41) muy por encima de la frontera de 3, que nos indica que se crearon etapas muy extremas por encima de lo que hubiera sufrido una distribución normal.

Por la parte de la volatilidad, este contexto creó clusters de inestabilidad que podemos ver en el gráfico de los residuos del principio del punto de volatilidad (bloque 4), donde los valores más extremos se sitúan al principio del gráfico. Esto es lo que captura la parte autorregresiva de nuestro modelo ARIMA de volatilidad, AR(1), que indica que un día de volatilidad es muy probable que vaya seguido de otro día de alta volatilidad.

Cuando ocurren estos impactos tan influyentes el mercado reacciona de manera instantánea, no gradual, y es por eso por lo que el test de Granger nos dice que ninguna variable es capaz de predecir o aportar información extra a la otra, y también por lo que el AR (1) no tenía coeficientes significativos y su rentabilidad anterior no podía predecir la futura, porque la rentabilidad y volatilidad de Palantir reacciona en base a factores macroeconómicos y no en base a patrones históricos.

5.3 RELACIÓN RENTABILIDAD-VOLATILIDAD

	Rentabilidad/año	Volatilidad/año	Ratio Sharpe
Palantir	4,13%	39,08%	0,10

La rentabilidad al año podemos ver que es una cifra baja (ya que también está teniendo en cuenta las cifras de 2022 (que es el año que más afectó a Palantir, ya que 2024 tuvieron muy buenas cifras de rentabilidad). Además si miramos la volatilidad es casi el doble de la volatilidad que presenta el mercado (NASDAQ), que suele estar entre 15% y 20%. Lo de que la rentabilidad sea tan alta afecta a que el ratio de Sharpe sea tan bajo (0,1), considerándose una acción bastante pobre, porque solo ganas 0,1 euros por cada euro de riesgo que inviertes. Esto significa que los inversores preferirán asumir ese riesgo tan alto para obtener más retornos en otras acciones o directamente invirtiendo en el mercado, o tener esa misma rentabilidad tan baja, pero con un riesgo mucho menor.




Figura 14: Gráfico relación estabilidad-volatilidad.

En este gráfico cada punto es un día, en el eje x está la volatilidad, es decir, cuanto mas a la derecha más volatilidad ese día, y el eje y la rentabilidad, cuánto más arriba más rentabilidad. En los días de baja volatilidad los puntos están agrupados en torno a 0, teniendo movimientos mínimos en la rentabilidad. Para los días de alta volatilidad (puntos de la derecha), los puntos están más dispersos, pero tanto arriba como abajo, lo que quiere decir que cuando hay alta volatilidad, solo hay más incertidumbre, pero no hay una tendencia ni de beneficio ni de pérdida, y por eso el Sharpe es tan pequeño, porque se asume riesgo para obtener muy poco ingreso, como ya hemos comentado antes. Como resumen de Palantir, la rentabilidad es prácticamente impredecible, por su modelo AR(1) sin coeficientes significativos. La volatilidad si parece más predecible ya que tiene todos los coeficientes

significativos. Esto cuadra bastante con la lógica del mercado, ya que el precio también depende mucho del contexto económico.

6. CONCLUSIONES Y LIMITACIONES

Tras haber completado lo requerido dentro del trabajo, hemos sacado las siguientes conclusiones. El análisis que hemos hecho sobre la rentabilidad nos hace llegar a la conclusión de que los rendimientos pasados de Palantir no son útiles para predecir los rendimientos futuros, al haber confirmado que la serie de rentabilidad se comporta como ruido blanco o dicho de otra forma, de una manera completamente aleatoria. Esto hace que se cumpla con la teoría del mercado eficiente. Por otra parte, la rentabilidad sí que es mucho más predecible ya que hemos podido identificar distintos clusters que siguen patrones, mediante el ARIMA (1,1,5) propuesto. Por ejemplo, un día con una volatilidad muy alta, es más probable que lo siga un día con cifras de volatilidad también muy altas, que un día con cifras más estables o cercanas a la media de volatilidad.

También hemos llegado a la conclusión, mediante el test de Granger, que las dos variables utilizadas durante el trabajo no son capaces de predecirse a corto plazo, es decir, no puedes utilizar el comportamiento de hoy de una variable para predecir el comportamiento de la otra el próximo día. Además, podemos asegurar que Palantir es un activo muy arriesgado, ya que dobla en cifras de volatilidad anual al mercado en el que opera, devolviendo muy poco a cambio, ya que su rentabilidad es demasiado baja para el riesgo que supone invertir en ella (Cifras del ratio de Sharpe).

Como hemos visto en Finanzas, el inversor probablemente elija un activo con riesgo prácticamente nulo como un activo de renta fija, que le de unas cifras de rentabilidad muy parecidas a unas cifras de riesgo casi nulo, o invertir en otro activo igual de arriesgado, pero que le reporte una rentabilidad mucho más alta. En resumen, Palantir en media de 2022-2024 no parece un activo muy atractivo, aunque el rendimiento de 2024 sea bastante bueno. La opción más razonable para invertir en Palantir sería invertir en posición larga y esperar un crecimiento que parece seguro, en el sector de la IA.

Entre las limitaciones que hemos encontrado, se encuentran principalmente los modelos. Los modelos ARIMA están enfocados a la linealidad y a la varianza estable, cosa que Palantir no cumple. Aunque con el ARIMA (1,1,5) hemos conseguido un comportamiento de ruido blanco para los

residuos, el test de Jarque-Bera nos indica que le cuesta mucho capturar las colas tan extremas que tiene la serie, es decir, el modelo se queda corto en casos de entornos muy cambiantes.

Por otro lado, al haber operado de manera individual cada variable, solo hemos podido crear predicciones basadas en el pasado de cada variable, pero no hemos podido meter otras variables como datos del índice del mercado NASDAQ, o datos de políticas monetarias.

7. BIBLIOGRAFÍA

Palantir Technologies Inc. (2024). *Annual Report 2023 (Form 10-K)*. U.S. Securities and Exchange Commission. <https://www.sec.gov/cgi-bin/browse-edgar?action=getcompany&CIK=1321655>

S&P Dow Jones Indices. (2023). *Palantir Technologies added to S&P 500 Index*. S&P Global. <https://www.spglobal.com>

NASDAQ Inc. (2024). *NASDAQ Composite Index historical data*. <https://www.nasdaq.com>

R Core Team. (2024). *R: A language and environment for statistical computing*. R Foundation for Statistical Computing. <https://www.R-project.org>

Pfaff, B. (2008). VAR, SVAR and SVEC models: Implementation within R package vars. *Journal of Statistical Software*, 27(4), 1–32.

Ryan, J. A., & Ulrich, J. M. (2023). *quantmod: Quantitative Financial Modelling Framework* [Paquete de R]. <https://CRAN.R-project.org/package=quantmod>

Trapletti, A., & Hornik, K. (2023). *tseries: Time Series Analysis and Computational Finance* [Paquete de R]. <https://CRAN.R-project.org/package=tseries>

Zeileis, A., & Hothorn, T. (2002). Diagnostic checking in regression relationships. *R News*, 2(3), 7–10.

Wickham, H. (2016). *ggplot2: Elegant Graphics for Data Analysis*. Springer-Verlag. <https://ggplot2.tidyverse.org>

Komsta, L., & Novomestky, F. (2022). *moments: Moments, Cumulants, Skewness, Kurtosis and Related Tests* [Paquete de R]. <https://CRAN.R-project.org/package=moments>

Roldán Casas, J. A. (2023). *La eficiencia en los mercados financieros*. Editorial Tirant lo Blanch.

Quiroga, E. (2017). Eficiencia en los mercados financieros y predicción de precios de los activos. *Visión de Futuro*, 21(2), 29–54. <https://www.redalyc.org/journal/5116/511653854005/511653854005.pdf>

Zubeldia, A. M., Díaz, B. y Zubiaurre, M. A. (2014). Rentabilidad, riesgo y eficiencia de los mercados bursátiles estadounidenses, español, mexicano y venezolano. *Revista de Dirección y Administración de Empresas*, 21, 1–26. <https://helvia.uco.es/handle/10396/13792>

Madura, J. (2015). *Mercados e Instituciones Financieras* (11ª ed.). Cengage Learning.

CNMV. (2021). *El mercado de valores y los productos de inversión: Manual para universitarios*.

Comisión Nacional del Mercado de Valores.

<http://www.cnmv.es/DocPortal/Publicaciones/Guias/ManualUniversitarios.pdf>

ANEXO Y CÓDIGO DE R APOYADO EN IA.

8. ANEXOS

Como añadido a lo que se pide el trabajo, y puesto que nos hemos propuesto conseguir predecir de una manera más fiel de lo que permiten las limitaciones del trabajo, el funcionamiento de Palantir, vamos a utilizar un modelo VAR bivalente, introduciendo una tercera variable externa que es la rentabilidad logarítmica del índice NASDAQ.

Primeramente descargamos desde R con el paquete “quantmod” los datos de rentabilidad del índice NASDAQ y ajustamos a las mismas métricas que pusimos para la rentabilidad de Palantir (690 observaciones).

Test ADF	P-valor
NASDAQ	0.01
Palantir	0.01

Para ambas variables rechazamos la H_0 , por lo que podemos decir que ninguna de las series tiene raíz unitaria y son estacionarias. Vamos a pasar con la selección de número de retardos que incluiremos dentro del modelo VAR.

AIC	HQ	SCE	FP
1	1	1	1

Lo que buscamos en este caso es el retardo que sea capaz de minimizar estos cuatro criterios de decisión (hemos añadido algunos que no están dentro del temario para tener más seguridad y poder contrastar). A continuación dejamos la tabla para que se puedan comprobar los valores.

```

--- TABLA COMPLETA DE CRITERIOS ---
> print(round(seleccion$criteria, 4))
      1      2      3      4      5      6      7      8      9     10
AIC(n) -16.7696 -16.7617 -16.7588 -16.7553 -16.7461 -16.7384 -16.7370 -16.7327 -16.7376 -16.7336
HQ(n)   -16.7541 -16.7360 -16.7228 -16.7090 -16.6895 -16.6714 -16.6597 -16.6452 -16.6398 -16.6255
SC(n)   -16.7297 -16.6952 -16.6657 -16.6356 -16.5998 -16.5655 -16.5375 -16.5066 -16.4849 -16.4543
FPE(n)  0.0000  0.0000  0.0000  0.0000  0.0000  0.0000  0.0000  0.0000  0.0000  0.0000

```

Llegamos a la conclusión de que con incluir solo un retardo es suficiente, ya que los demás retardos no aportan más información, solo ruido. Esto significa que para predecir la rentabilidad de hoy solo utilizaremos la de ayer, no la de más días atrás. Por tanto, la decisión es estimar un modelo VAR (1).

Ahora vamos a realizar el test de causalidad de Granger entre rentabilidad Palantir y rentabilidad NASDAQ.

Test de Granger NASDAQ - Palantir	P-valor
RETARDO 1	0,34
RETARDO 2	0,1985
RETARDO 5	0,0757
RETARDO 10	0,0067

Test de Granger Palantir - NASDAQ	P-valor
RETARDO 1	0,239
RETARDO 2	0,2491
RETARDO 5	0,1033
RETARDO 10	0,0133

Aquí podemos ver una contradicción con lo que hemos dicho antes de elegir un VAR (1). Esto es porque el test de Granger nos dice que hasta el retardo 10 no hay causalidad entre las variables. Por tanto, la relación entre ambas variables existe pero no es de forma inmediata (la rentabilidad de ayer del NASDAQ no predice la rentabilidad de Palantir de hoy), pero si que lo puede hacer con una diferencia de 10 días.

Además podemos ver que hay causalidad entre ambas variables, es decir, es bidireccional. Esto se puede explicar fácilmente, ya que como hemos dicho, Palantir es una de las empresas líderes del sector IA y un cambio dentro de su rentabilidad también puede afectar a la rentabilidad del índice NASDAQ. Por tanto, a pesar de haber elegido anteriormente un VAR (1) por los criterios anteriores, ahora utilizaremos un VAR (10) porque es con 10 retardos cuando aparece la relación de causalidad.




Figura 15: Respuesta de Palantir a Shock de NADAQ.

Este gráfico nos enseña que le pasa a Palantir cuando el NASDAQ tiene un movimiento poco habitual. Para aclarar, la línea negra es la respuesta de Palantir estimada, es decir el efecto medio del movimiento del NASDAQ. Las líneas rojas son los intervalos de confianza del 95%.

En los primeros días, del 1 al 5, si el shock del NASDAQ es positivo, la reacción de Palantir es negativa, baja ligeramente, ya que probablemente los inversores cambien de estrategia a activos más seguros o directamente invertir al mercado. A partir del día 5, hasta aproximadamente el día 10 Palantir se estabiliza y comienza a subir, entonces el shock positivo del NASDAQ tarda en afectar positivamente a Palantir unos 9 o 10 días, coincidiendo con lo que nos dice el test de Granger. A partir del día 10 se estabiliza en 0 por lo que pierde su efecto completamente. En resumen, Palantir tarda unos 10 días en reaccionar completamente a un shock del NASDAQ, y la reacción se divide en dos fases, la primera en la que reacciona negativamente (que pasa durante los primeros días) y la segunda en la que se estabiliza y sube la rentabilidad reaccionando positivamente).

En caso de que el shock que sufre NASDAQ sea negativo en lugar de positivo, el efecto es el mismo pero a la inversa.




Figura 16: Respuesta de NASDAQ a shock de Palantir

Ahora vamos a ver lo que pasa de manera inversa, cuando Palantir sufre un shock, cual es la respuesta del índice NASDAQ. Aquí la relación es mucho más simple e interpretable, de forma casi inmediata la rentabilidad del NASDAQ sube radicalmente. A partir del día 3 el efecto ya se ha estabilizado y desaparece.

ENLACE CÓDIGO R (FUENTE DE GRÁFICOS Y RESULTADOS NUMÉRICOS):

[CÓDIGO R RENT-VOL](#)